



UniDeep

Data Manipulate Cheat Sheet -- R vs Python

Global Setting		Load & Write Data	
<code>install.packages()</code>	<code>import()</code>	<code>read.csv()</code>	<code>pd.read_csv()</code>
<code>getwd()</code>	<code>os.getcwd()</code>	<code>write.csv(, row.name=F)</code>	<code>df.to_csv(, index=False)</code>
<code>setwd()</code>	<code>os.chdir()</code>	<code>read.table()</code>	<code>pd.read.table()</code>
<code>set.seed()</code>	<code>np.random.seed()</code>	<code>write.xlsx()</code>	<code>df.to_excel()</code>
<code>ls()</code>	<code>os.listdir()</code>	Data Type	
<code>rm()</code>	<code>os.remove()</code>	<code>as.numeric()</code>	<code>as.numeric()</code>
Data Slicing		<code>as.character()</code>	<code>as.character()</code>
<code>df[1:10,]</code>	<code>df.iloc[0:10,]</code>	<code>as.factor()</code>	<code>as.factor()</code>
<code>df[, 1:3]</code>	<code>df.iloc[:, 1:3]</code>	<code>as.data.frame()</code>	<code>as.data.frame()</code>
<code>df[, col]</code>	<code>df.loc[:, col]</code>	<code>as.Date()</code>	<code>as.Date()</code>
<code>df\$col</code>	<code>df.col</code>	Basic Function	
<code>df[df\$col in c(),]</code>	<code>df.loc[df.col.isin([])]</code>	<code>seq()</code>	<code>range()</code>
<code>df[df\$col == value]</code>	<code>df.loc[df.col == value]</code>	<code>rep()</code>	<code>np.repeat()</code>
<code>df[df\$col == value, col] = value</code>	<code>df.loc[df.col == value,] = value</code>	<code>length()</code>	<code>len()</code>
<code>df[, -1]</code>	<code>df.drop(df.columns[1], 1)</code>	<code>table()</code>	<code>pd.crosstab()</code>
<code>df[, c(col1, col2)] = NULL</code>	<code>df.drop([col1, col2], 1)</code>	<code>unique()</code>	<code>set()</code>
Data Wrangling		<code>class()</code>	<code>type()</code>
<code>df[order(col),]</code>	<code>df.sort_values([col])</code>	<code>strsplit()</code>	<code>str.split()</code>
<code>df[order(-col),]</code>	<code>df.sort_values([col], ascending=[0])</code>	<code>is.null()</code>	<code>pd.isnull()</code>
<code>colnames()</code>	<code>df.columns.values()</code>	<code>is.na()</code>	<code>pd.isna()</code>
<code>row.names()</code>	<code>df.index()</code>	<code>paste(A, B, sep='_')</code>	<code>%s_%s%(A, B)</code>
<code>rbind()</code>	<code>pd.concat([,], axis=0)</code>	<code>setdiff(A, B)</code>	<code>[x for x in A if x not in B]</code>
<code>cbind()</code>	<code>pd.concat([,], axis=1)</code>	<code>grep()</code>	<code>re.findall()</code>
<code>str()</code>	<code>df.info()</code>	Basic Statistics	
<code>dim()</code>	<code>df.shape()</code>	<code>mean()</code>	<code>np.mean()</code>
<code>head()</code>	<code>df.head()</code>	<code>rowSums()</code>	<code>df.sum(1)</code>
<code>summary()</code>	<code>df.describe()</code>	<code>colSums()</code>	<code>df.sum(0)</code>
<code>merge(, by)</code>	<code>pd.merge(, on)</code>	<code>colMeans()</code>	<code>df.mean(0)</code>
<code>merge(, all.x=T)</code>	<code>pd.merge(, how='left')</code>	<code>rowMeans()</code>	<code>df.mean(1)</code>
<code>merge(, all.y=T)</code>	<code>pd.merge(, how='right')</code>	<code>var()</code>	<code>np.var()</code>
<code>merge(, all.x=T, all.y=T)</code>	<code>pd.merge(, how='outer')</code>	<code>sd()</code>	<code>np.std()</code>
<code>apply(, MARGIN = 1, function(x))</code>	<code>df.apply(lambda x: , axis=1)</code>	<code>t.test()</code>	<code>sp.stats.ttest_ind()</code>
<code>apply(, MARGIN = 2, function(x))</code>	<code>df.apply(lambda x: , axis=0)</code>	<code>rnorm()</code>	<code>sp.stats.norm.rvs()</code>
<code>tidyr::drop_na(df)</code>	<code>df.dropna()</code>	<code>dnorm()</code>	<code>sp.stats.norm.pdf()</code>
<code>df[is.na(df)] = value</code>	<code>df.fillna(value)</code>	<code>lm()</code>	<code>linear_model.LinearRegression()</code>
<code>df[, mean(col3), .(col1, col2)]</code>	<code>df.groupby([col1, col2])[col3].mean()</code>		
<code>df[, .N, .(col1, col2)]</code>	<code>df.groupby([col1, col2]).size()</code>		
<code>unique()</code>	<code>df.drop_duplicates()</code>		
<code>sample_n()</code>	<code>df.sample()</code>		
<code>dcast(, ~, value.var, fun)</code>	<code>pd.pivot_table(, index, columns, values, aggfunc)</code>		
<code>melt(, id.vars = c(col))</code>	<code>pd.melt(, id_vars)</code>		

